CIFAR-10 Image Classification with Validation-Controlled Model Selection and Batch Normalization Analysis

黄德超　23300660009

2026 年 6 月 12 日

摘要

本文围绕 CIFAR-10 图像分类任务构建了一套可审计的实验流程，重点考察模型结构、训练 recipe、最终测试协议以及 Batch Normalization（BN）对优化行为的影响。开发阶段将官方训练集划分为 45,000 张 `train_dev` 图像和 5,000 张 `val_dev` 图像，所有模型选择、checkpoint selection 和 BN 分析均限制在该开发划分内完成；官方测试集仅在 replay checkpoint 和评估策略锁定后使用。实验从 SimpleCNN 和 VGG-A 出发，逐步比较 CompactResNetV2、PreActResNet-W4/W6 以及 W4 recipe 分支 L3，并在完整 50,000 张官方训练图像上执行 full-train replay。最终 locked replay rows 中，W6 达到 96.26% official test accuracy，L3-lowLR 达到 96.10%，W4 达到 95.55%。BN mini-research 在受控 VGG-A 设置中显示，BN 提升验证准确率与收敛速度，在 expanded short LR stress 中承受更高 usable base learning rate，并在 train-mode scale-invariance 与局部梯度预测性 probe 中表现出更稳定的优化行为。本文同时保留若干 non-claims：BN 并未在所有学习率条件下缩小 loss envelope，也不能从单一 VGG-A/CIFAR-10 设置推断其普遍降低梯度 Lipschitz estimate。

Keywords: CIFAR-10, validation protocol, full-train replay, Batch Normalization, loss landscape, gradient predictiveness

1　Introduction and Experimental Setup

本文研究 CIFAR-10 图像分类中的模型选择、最终评估和 Batch Normalization 机制分析问题。CIFAR-10 包含 50,000 张官方训练图像和 10,000 张官方测试图像，覆盖 airplane、automobile、bird、cat、deer、dog、frog、horse、ship 和 truck 十个类别。由于深度学习实验容易在反复调参中隐式使用测试集，本文将实验重点放在一个严格的验证集控制流程上：开发阶段只使用官方训练集内部划分出的 `train_dev`/`val_dev`，官方测试集仅用于测试前锁定 checkpoint 的一次性 held-out evaluation。

实验设计围绕三个相互关联的问题展开。第一，比较不同模型结构在准确率、参数量、显存和训练时间之间的权衡。第二，使用 validation-controlled ablation 和 staged selection 得到可解释的 replay stop points，而不是根据 official test 结果反向选择模型。第三，在受控 VGG-A with/without BN 设置下，考察 BN 对训练动态、学习率鲁棒性、尺度不变性和局部梯度行为的影响。由此，报告的主要内容可概括为以下三条主线：

1. **分类性能：**从 SimpleCNN、VGG-A 到 CIFAR-PreActResNet 候选模型，逐步比较验证精度、参数量、训练代价和 locked full-train replay 结果。
2. **模型选择：**通过结构筛选、recipe ablation、Stage B 和 Stage C-lowLR 决定 replay stop points，并在完整 50,000 张训练图像上复现实验选择。
3. **BN 机制分析：**在 VGG-A 受控对照中分析 BN 对收敛速度、learning-rate stress、局部 loss 几何、scale invariance 和 gradient predictiveness 的影响。

表 1 本项目的主要实验设置与 replay 提交信息。

项目	设置
数据集	CIFAR-10, 50,000 official train images + 10,000 official test images
代码与权重	https://github.com/adehuang41/deep_learning_pj2; https://www.modelscope.cn/models/adehuang41/deep_learning_pj2
开发划分	`train_dev`: 45,000; `val_dev`: 5,000; split seed = 42
split 文件	`splits/cifar10_train45000_val5000_seed42.json`
开发选择标准	best validation accuracy, validation loss as tie-breaker
Replay 训练集	all 50,000 official train images, no validation loader during replay
Replay 测试行	W4 raw e205; W6 raw e193; L3-fast raw e133; L3-lowLR EMA e230
Replay 评估	clean/eval transform, no horizontal-flip TTA
Replay lock	`results/fulltrain_replay_20260611/protocol/fulltrain_replay_test_lock.json`
Replay 输出	`results/fulltrain_replay_20260611/metrics/fulltrain_replay_official_test_results.csv`

1.1 Train/Validation/Test Protocol

开发阶段的所有模型选择均基于 `train_dev`/`val_dev`。官方训练集按类别均衡划分：每类 4,500 张进入 `train_dev`，每类 500 张进入 `val_dev`，因此验证集总数为 5,000。该划分既保持类别平衡，也避免 class imbalance 对 checkpoint ranking 产生额外影响。

`val_dev` 在本文中承担三类开发职责。第一，它用于 checkpoint selection，每个训练 run 按 validation accuracy 选择 best checkpoint，并以 validation loss 作为 tie-breaker。第二，它用于候选模型的 Pareto 比较，例如 W4、W6 和 CompactResNetV2 的阶段性选择。第三，它用于 BN mini-research 中的 controlled comparison 和 probe evaluation。官方测试集不参与以上任一开发步骤。

full-train replay 阶段不再使用 `val_dev` 进行训练或中途选择，而是在完整 50,000 张 official train images 上从头训练。开发划分文件在 replay 中仅作为 provenance 记录，用于说明 replay stop points 来自此前的验证阶段选择。训练脚本明确关闭 validation loader 和 official-test loader；官方测试只由 replay-specific evaluator 在 lock 文件存在且 checkpoint hash 匹配后执行。

replay 协议的公平性依赖三个约束。第一，W4、W6 和 L3 的 stop points 在 official test 前写入 `fulltrain\_replay\_training\_lock.json`。第二，L3-fast 和 L3-lowLR 被定义为两个不同的预声明问题，不能在看到 test accuracy 后二选一。第三，official-test evaluator 只接受 `fulltrain\_replay\_test\_lock.json` 中的 checkpoint，不能临时传入其他模型。

1.2 Code Structure and Reproducibility

代码结构按照模型、训练流程、评估流程和实验记录分层组织。模型定义位于 `src/models/`；常规训练主循环位于 `src/train.py`；数据划分与 dataloader 位于 `src/data.py`；full-train replay 由 `src/fulltrain_replay.py` 执行；replay official test 由 `src/fulltrain_replay_official_test.py` 执行。训练脚本位于 `scripts/`，配置文件位于 `configs/`，实验输出按类型保存到 `results/metrics/`、`results/figures/`、`results/tables/` 和 `results/protocol/`。

复现实验时，协议文件是解释结果的核心依据。模型训练可以重新运行，但报告中的 replay official-test numbers 应以 replay lock 和 frozen metrics 为准；若重新训练并重新测试，应视为新的实验版本，而不应覆盖 `results/fulltrain_replay_20260611/` 中的冻结记录。本文不要求 bitwise reproducibility，因此保留 `cudnn_benchmark=True`；固定 seed 和固定 split 的作用是保证实验协议公平，而不是保证每次浮点轨迹完全一致。

1.3 Architecture Summary

为了明确回应模型结构要求，表 2 汇总了本报告主要模型的卷积结构、池化、分类器、激活函数、BatchNorm、dropout 和 residual connection。SimpleCNN 和 VGG-A 用作 baseline/control；CompactResNetV2 是中间高效候选；PreActResNet-W4/W6/L3 是最终 replay 主线中的残差模型。L3 与 W4 使用相同结构规模，区别在训练 recipe 中的 weight decay 和后续 checkpoint policy。

2 Baseline and Controlled VGG-A Models

2.1 SimpleCNN Baseline

SimpleCNN 作为低复杂度 baseline，用于给出标准 CIFAR-10 预处理、固定开发划分和 validation checkpoint selection 下的小模型性能下界。该模型只有约 0.62M 参数，训练速度最快，峰值显存约 0.09 GiB，早期 locked official-test accuracy 为 86.72%。

表 2 Architecture Summary Table。

Model	Conv blocks	Pooling	FC / classifier	Activation / BN / Dropout / Residual	Params
SimpleCNN	3 conv layers: 3→32→64→128, all 3×3	MaxPool ×3	Flatten, 2048→256→10	ReLU; no BN; FC dropout 0.3; no residual	0.62M
VGG-A	8 conv layers: 64, 128, 256×2, 512×4	MaxPool ×5	512→512→512→10	ReLU; no BN; FC dropout 0.5; no residual	9.75M
VGG-A BN	Same VGG-A conv layout, conv bias removed	MaxPool ×5	same as VGG-A	ReLU; BN after every conv; FC dropout 0.5; no residual	9.75M
CompactV2	Stem + 4 residual stages, channels 64/128/256/384, blocks 2/2/2/2, ECA-lite	global avg	dropout + linear 10-way	SiLU; BN; dropout 0.2 + drop path; residual	7.75M
PreAct W4 / L3	Stem + 3 pre-activation residual groups, depth 28, widths 64/128/256	global avg	linear 10-way	ReLU; pre-activation BN; block dropout 0.3; residual	5.85M
PreAct W6	Same depth as W4, wider residual groups, widths 96/192/384	global avg	linear 10-way	ReLU; pre-activation BN; block dropout 0.3; residual	13.14M

结果表明，SimpleCNN 已能学习 CIFAR-10 的主要视觉模式，但在细粒度类别上仍存在明显限制。其错误率为 13.28%，高于后续 VGG-A 和 full-train replay 中的 PreActResNet 候选。该差距说明，在 CIFAR-10 上，模型容量、深度结构、残差连接和训练 recipe 都会显著影响最终性能。

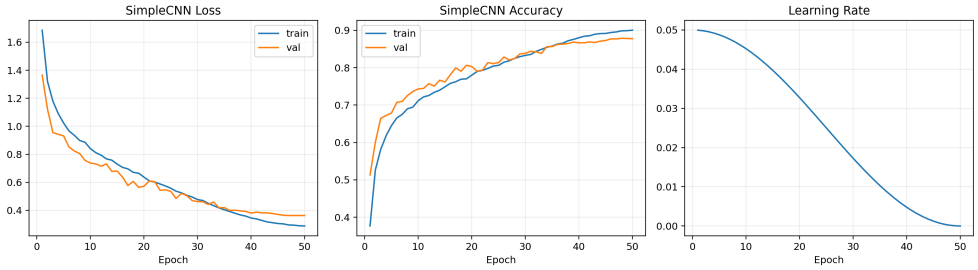


图 1 SimpleCNN baseline 的 train/validation 曲线。baseline 的主要作用是提供稳定可复现的低复杂度参照。

2.2 VGG-A without BatchNorm

VGG-A no BN 是 BatchNorm 对照实验中的 control row。它的结构比 SimpleCNN 更深，参数量达到约 9.75M，但没有 BatchNorm 层。由于 VGG-A 没有残差连接，且训练过程中中间层激活和梯度更容易受到尺度变化影响，no-BN 版本在收敛速度和稳定性上都不如 BN 版本。

在早期 locked official test 中，VGG-A no BN 达到 87.85% accuracy，优于 SimpleCNN，但提升幅度有限。该结果表明，单纯增加参数并不能保证在固定训练 recipe 下显著提升泛化性能。VGG-A no BN 的 test loss 为 0.4783，高于 VGG-A BN 的 0.4291，也高于 full-train replay 中任一 PreActResNet row。

2.3 VGG-A with BatchNorm

VGG-A BN 是受控实验中的 treatment row。它与 no-BN 版本保持相同主干结构，只在卷积层后加入 BatchNorm，因此两者可以用于更直接地观察 BN 的影响。早期 locked official test 中，VGG-A BN 达到 89.17% accuracy，比 no-BN 高 1.32 percentage points，比 SimpleCNN 高 2.45 percentage points。

VGG-A BN 的参数量只比 no-BN 多约 2,752 个参数，增量相对 9.75M 的主干规模可以忽略。因此两者性能差异主要来自归一化机制，而非参数规模本身。后续 BN P0 的验证集和局部几何分析也支持这一解释：BN 在本项目设置中改善了 VGG-A 的优化行为。

表 3 早期 baseline/control rows 与原 W4 full-train row 的效率与性能。

Model	Params	Train time	Epoch time	Peak memory	Test acc
SimpleCNN baseline	620,362	530.49 s	10.58 s	0.09 GiB	86.72%
VGG-A no BN	9,750,922	531.92 s	10.39 s	0.27 GiB	87.85%
VGG-A BN	9,753,674	533.16 s	10.41 s	0.33 GiB	89.17%
Original W4 full-train	5,849,050	4950.79 s	23.96 s	3.41 GiB	95.52%

3 Validation-Stage Model Selection and Ablation Path

3.1 Selection Roadmap

replay stop point 均由 `val_dev` 上的阶段性选择决定，而不是由 test set 比较得到。本文采用两条互相配合的筛选线。第一条是结构筛选：比较 W4、W6 和 CompactResNetV2，决定保留哪个结构家族进入更长训练。第二条是 W4 recipe ablation：固定 W4 结构，只改变 activation、loss、optimizer 或 weight decay，先用 50 epochs 快速筛查，再把短程胜出的候选恢复训练到 150 epochs。

该分层设计避免了两个常见混淆。第一，50-epoch 短程结果不能直接作为最终结论，因为 optimizer 和 regularization 的早期优势可能在长训练中消失。第二，结构变化和 recipe 变化不宜混在同一张排行榜中比较，否则无法区分性能差异来自网络结构还是训练超参数。所有筛选均使用同一个 `train_dev`/`val_dev` split、seed 42 和 checkpoint selection 规则，并且不使用 official test。

3.2 50-Epoch Recipe Screening

50-epoch ablation 的基准是 `L0_current_recipe`，即复用 W4 Stage B 的 epoch-50 记录。该复用在使用前检查了配置、split 文件、seed、scheduler semantics 和 dataloader 设置，确认其与新的 ablation base config 一致。筛查使用 `scheduler_t_max=150` 且在

表 4 Validation-controlled staged elimination roadmap。

Stage	Budget	Promoted / retained	Eliminated / not used
Structure screen	50 epochs	W4, W6, CompactV2 都进入 Stage B	无；只做早期可行性筛查
Recipe screen	50 epochs	L3 weight decay 10^{-4}, O1 AdamW, O2 Adam	A1 LeakyReLU, A2 SiLU, L1 no label smoothing, L2 focal loss
Stage B	150 epochs	W4 and W6	CompactV2 被 W4 支配
Recipe continuation	150 epochs	L3 weight decay 10^{-4}	O1 AdamW and O2 Adam 低于 L0 baseline
Stage C diagnostic	250 epochs	作为诊断证据保留	旧 continuation curve 不作为主报告证据
Clean C-lowLR	100 ft epochs	W4, W6, L3-fast, L3-lowLR 进入 replay lock	不在 official test 后二次筛选

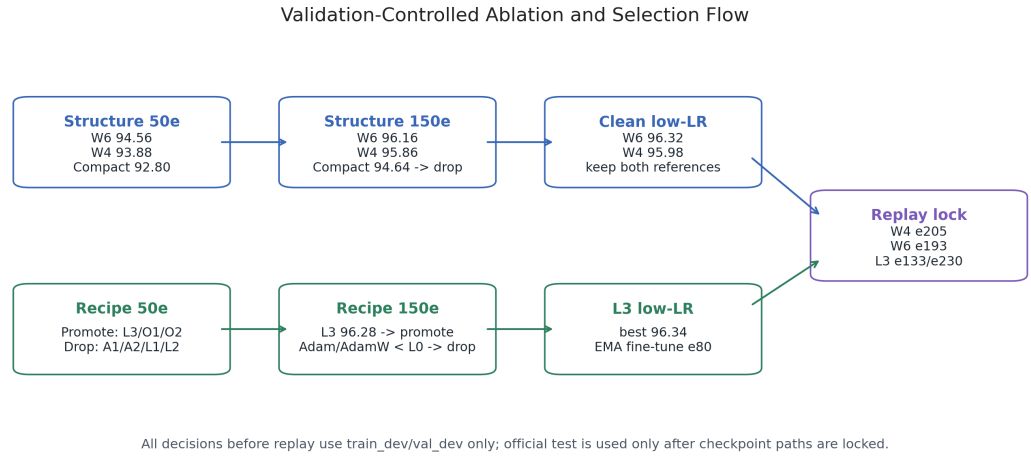


图 2 Validation-controlled ablation and selection flow。结构筛选与 recipe ablation 分开推进，最后汇合到 replay lock。

epoch 50 暂停，因此它不是完整的 50-epoch cosine run，而是 150-epoch 训练计划中的早期截面。

结果显示，activation 和 loss 方向没有通过初筛。LeakyReLU 和 SiLU 分别只有 85.84% 和 83.36% best validation accuracy，明显低于 L0 的 88.92%。去掉 label smoothing 的 CE 和 focal loss 虽然 validation loss 数值较低，但 loss function 本身不同，不能直接用 loss 数值跨目标比较；按预声明的 accuracy-first 规则，它们分别只有 86.22% 和 85.84%，也被淘汰。

短程结果中最有希望的是 optimizer 与 weight decay 分支。O1 AdamW 达到 92.04%，O2 Adam 达到 90.24%，L3 weight decay 10^{-4} 达到 91.58%。因此这三条被提升到 150-epoch continuation，但并不构成最终选择；该阶段仅支持“进入长程复核”的结论。

表 5 W4 recipe 50-epoch screening results。

Run	Factor	Changed setting	Best val acc	Δ vs L0	Decision
L0	Control	current W4 Stage B recipe	88.92%	+0.00 pp	control
A1	Activation	LeakyReLU	85.84%	-3.08 pp	eliminate
A2	Activation	SiLU	83.36%	-5.56 pp	eliminate
L1	Loss	CE without label smoothing	86.22%	-2.70 pp	eliminate
L2	Loss	focal loss, $\gamma = 2$	85.84%	-3.08 pp	eliminate
L3	Regularization	weight decay 10^{-4}	91.58%	+2.66 pp	promote
O1	Optimizer	AdamW, lr 10^{-3}	92.04%	+3.12 pp	promote
O2	Optimizer	Adam, lr 3×10^{-4}	90.24%	+1.32 pp	promote

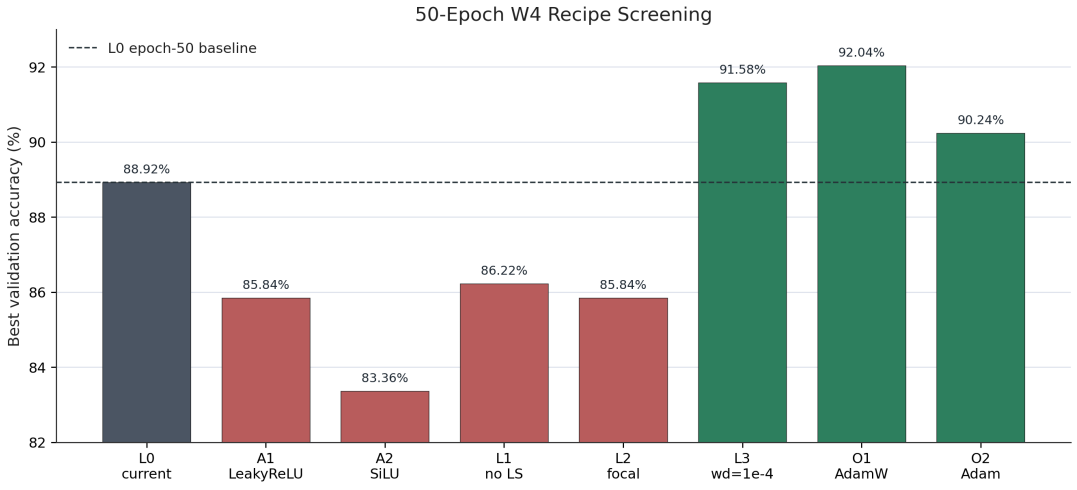


图 3 W4 recipe 50-epoch screening。绿色候选只表示进入 150-epoch follow-up，不表示已经成为最终 recipe。

3.3 150-Epoch Continuation and Recipe Elimination

150-epoch continuation 的关键是恢复 epoch-50 checkpoint，并同时恢复 optimizer、scheduler 和随机状态，使候选分支延续同一条训练轨迹。该设计回答了一个更严格的问题：50-epoch 领先的候选如果继续训练到与 W4 Stage B 相同的 150-epoch budget，是否仍然超过 L0?

结果改变了 50-epoch 的排序。AdamW 在 50 epochs 时最高，但 150 epochs 后只有 95.28%，比 L0 W4 Stage B 的 95.86% 低 0.58 pp；Adam 最终为 95.36%，低 0.50 pp。这说明 optimizer 的短程优势没有转化为长程优势，因此 O1/O2 被淘汰。唯一仍超过 L0 的是 L3 weight decay 10^{-4}，best validation accuracy 为 96.28%，比 L0 高 0.42 pp，best epoch 为 133。

表 6 W4 recipe 150-epoch continuation results。

Run	Best val acc	Δ vs L0	Best epoch	Final val acc	Decision
L3 weight decay 10^{-4}	96.28%	+0.42 pp	133	96.24%	promote
L0 W4 Stage B	95.86%	+0.00 pp	148	95.84%	baseline
O2 Adam	95.36%	-0.50 pp	143	95.34%	do not promote
O1 AdamW	95.28%	-0.58 pp	143	95.26%	do not promote

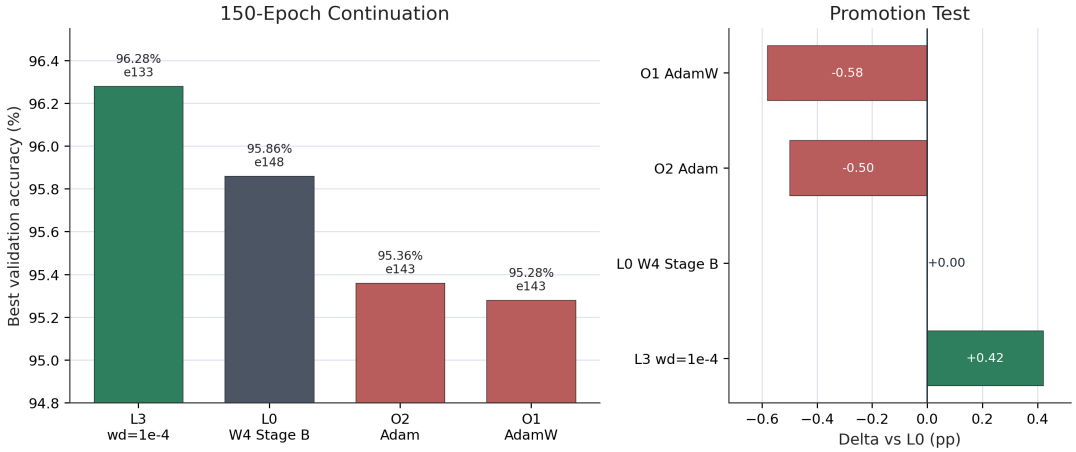


图 4 150-epoch continuation。Adam/AdamW 的短程优势消失，只有 L3 weight decay 10^{-4} 超过 L0。

3.4 Structure Candidates and Stage Progression

结构筛选与 recipe ablation 平行推进。Stage A 的 50-epoch 结构筛选中，W6、W4 和 CompactResNetV2 都表现可行，因此三者都进入 Stage B。到 Stage B 的 150 epochs 后，CompactResNetV2 的 best validation accuracy 为 94.64%，低于 W4 的 95.86%，而参数量和显存也没有形成足够优势，因此被淘汰为主要候选，只作为开发证据保留。

W4 和 W6 则继续进入 clean Stage C-lowLR。W6 在 Stage B 上比 W4 高 0.30 pp，在 Stage C-lowLR 上比 W4 高 0.34 pp，但 W6 参数量为 13.14M，是 W4 的约 2.25 倍。因此后续不把 W6 写成无条件最优，而是保留为 larger reference；W4 保留为 Pareto-cost reference。

L3 是从 W4 recipe ablation 中产生的分支，而不是新的网络结构。它在 150-epoch base run 的 best epoch 为 133，因此 replay 中保留 L3-fast raw e133；它在后续 low-LR fine-tune 中 best validation accuracy 达到 96.34%，EMA 权重在 fine-tune epoch 80 匹配最佳点，因此 replay 中也保留 L3-lowLR EMA e230。

3.5 Stage B, 250-Epoch Diagnostic, and Clean Stage C-lowLR

Stage B 的结果说明 W6 在验证准确率上确实略强，但代价也更高。W4 Stage B 的 best val accuracy 为 95.86%，W6 Stage B 为 96.16%，差距为 0.30 percentage points。

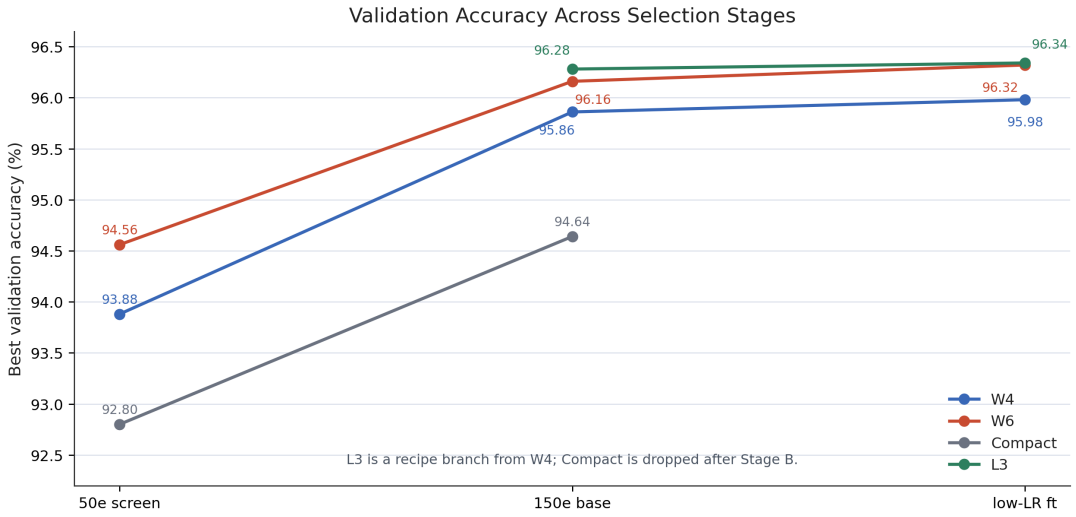


图 5 Validation accuracy across selection stages。CompactResNetV2 在 Stage B 后退出，L3 作为 W4 recipe branch 加入。

表 7 Validation-stage Pareto comparison。所有结果均来自 `train_dev/val_dev`，不是 official test。

Run	Best val acc	Epoch	Params	Peak memory	Decision
CompactResNetV2 Stage B	94.64%	138	7.75M	4.98 GiB	被 W4 支配，仅作为开发证据保留
W4 Stage B	95.86%	148	5.85M	3.43 GiB	进入 Stage C-lowLR
W6 Stage B	96.16%	142	13.14M	5.56 GiB	进入 Stage C-lowLR
L3 150-epoch base	96.28%	133	5.85M	3.43 GiB	replay raw epoch 133
W4 Stage C-lowLR	95.98%	55 ft	5.85M	3.47 GiB	replay raw epoch 205
W6 Stage C-lowLR	96.32%	43 ft	13.14M	5.67 GiB	replay raw epoch 193
L3 Stage C-lowLR	96.34%	80 ft	5.85M	3.47 GiB	replay EMA epoch 230

此时还不能直接锁定 W4，因为更大模型在较长训练或低学习率阶段可能进一步拉开差距。因此实验继续进入 Stage C。

中间还执行过 W4/W6 的 250-epoch continuation，用于检查单纯延长训练预算是否会改变 Pareto 关系。该诊断 run 中 W4 和 W6 的 best validation accuracy 分别达到 96.32% 和 96.58%。但随后 audit 发现旧 continuation 曲线包含 scheduler-state / high-LR restart artifact，因此该旧曲线不再作为主报告图，也不用于 replay stop point。该诊断暴露了 scheduler 语义问题，并促使后续改为显式的 clean Stage C-lowLR：从 150-epoch base checkpoint 出发，重新初始化 optimizer 和 EMA，使用清晰定义的 low-learning-rate fine-tuning schedule。

Stage C-lowLR 后，W4 best val accuracy 为 95.98%，W6 为 96.32%。W6 仍然领先，但领先幅度只有 0.34 percentage points，而参数量从 W4 的 5.85M 增加到 13.14M，峰值显存也从 3.47 GiB 上升到 5.67 GiB。因此开发阶段保留两条信息：W4 是更好的 Pareto-cost reference，W6 是更高验证精度的 larger reference。

后续 full-train replay 没有用 official test 来重新选择 W4/W6/L3，而是把 W4、W6 以及 L3 的两个预声明 checkpoint 都作为 locked rows 一次性评估。因此，即使 official test 上某一行更高，也不会改变之前的选择逻辑。

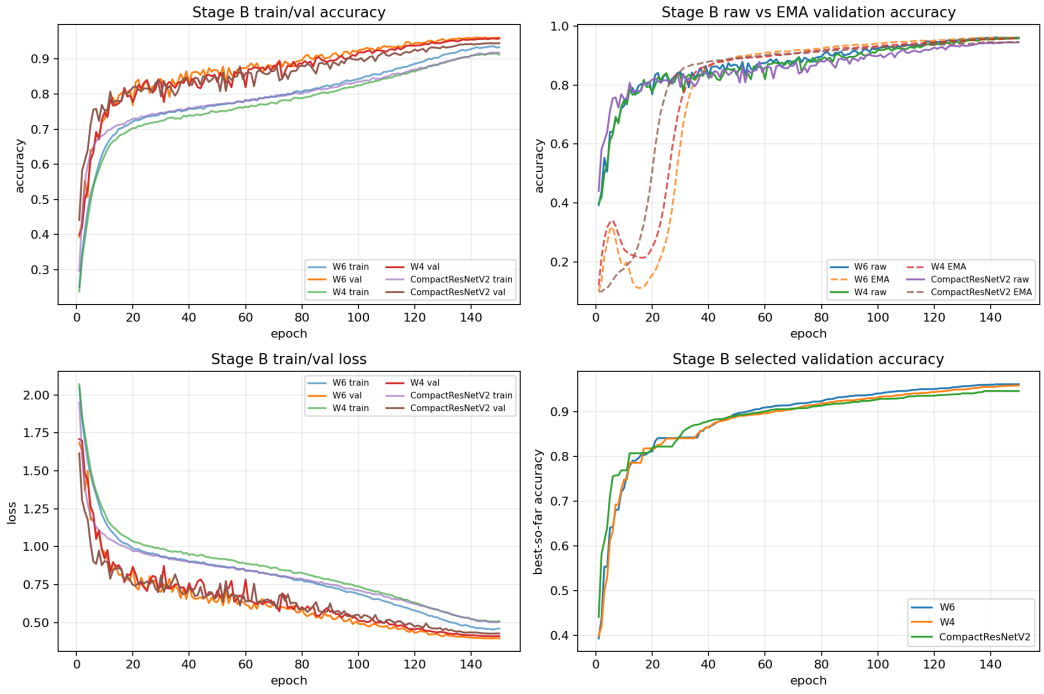


图 6 Stage B 候选模型训练/验证曲线。该阶段用于比较 W4、W6 和 CompactResNetV2。

3.6 Full-Train Replay Recipe

full-train replay 从头开始在完整 50,000 张 official train images 上训练，不再使用 `val_dev` 做中途选择。共同 recipe 为：phase 1 使用 150 epochs base cosine training；phase 2 重新初始化 optimizer 和 EMA，使用 `LowLRFineTuneScheduler`，其中

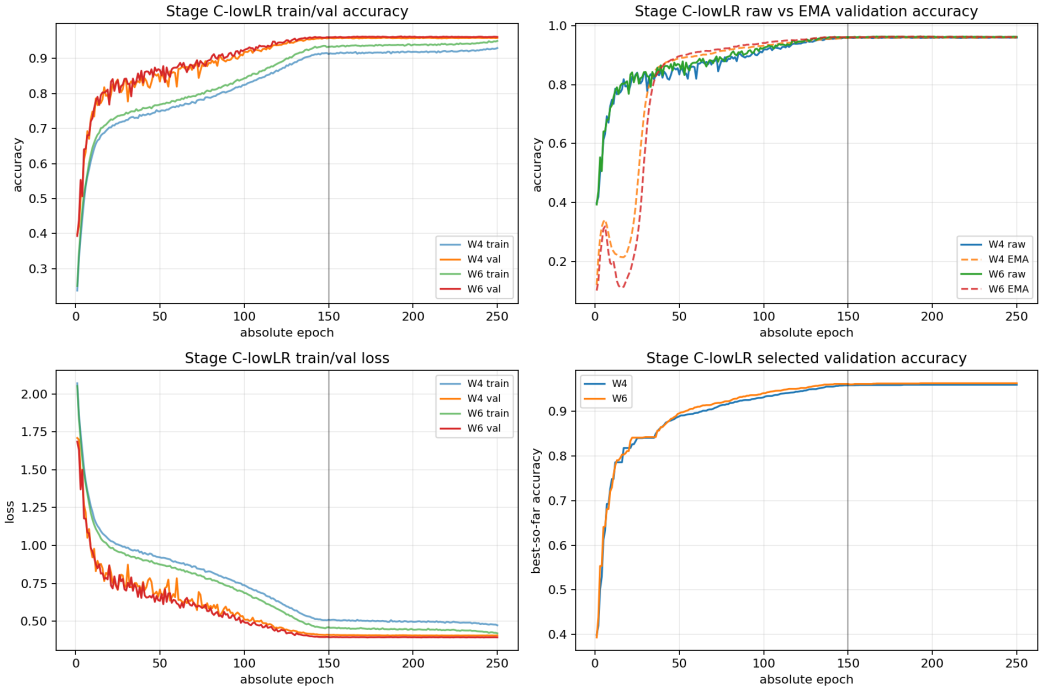


图 7 Stage C-lowLR 训练/验证曲线。W4 与 W6 在显式低学习率阶段继续提升；竖线表示 epoch 150 后进入 clean low-LR fine-tuning。

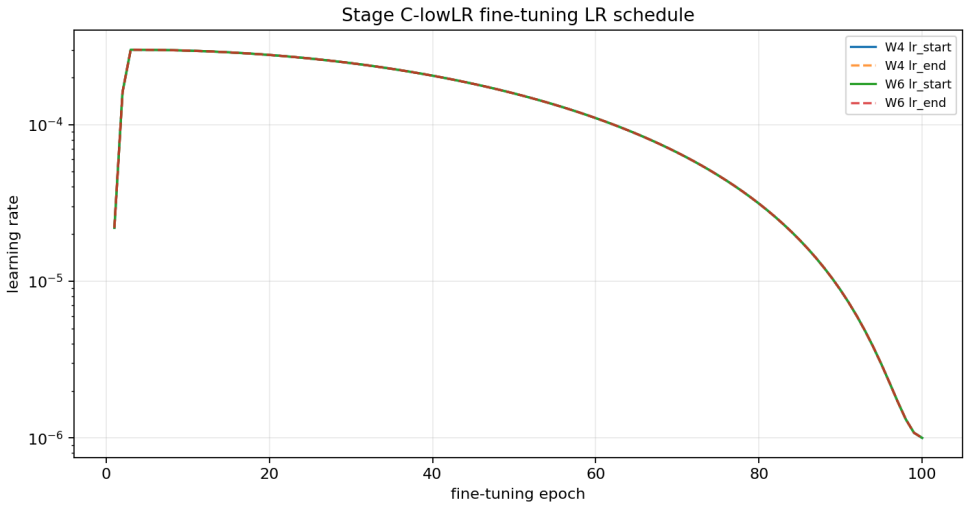


图 8 Clean Stage C-lowLR 学习率曲线。该图对应显式 low-learning-rate fine-tuning recipe，用于支持验证阶段的 Pareto 决策。

`total_epochs=100`、`max_lr=3e-4`、`min_lr=1e-6`、warmup epochs = 3。关键点是 low-LR scheduler 不压缩到 43/55/80 epochs，而是保持与开发阶段一致的 100-epoch 时间尺度，然后在预声明 epoch 停止。

表 8 Full-train replay locked checkpoints。所有 stop points 均在 official test 前固定。

Row	Global epoch	Weights	Params	Source
W4	205	raw	5.85M	W4 dev-val lowLR fine-tune epoch 55
W6	193	raw	13.14M	W6 dev-val lowLR fine-tune epoch 43
L3-fast	133	raw	5.85M	L3 dev-val best base epoch 133
L3-lowLR	230	EMA	5.85M	L3 dev-val lowLR EMA fine-tune epoch 80

replay 的训练日志中没有 validation accuracy，也没有 test accuracy；只记录 train-mode loss、train-mode accuracy、学习率、时间和资源指标。train-mode accuracy 受 RandAugment、Cutout、dropout 和 label smoothing 影响，因此它低于 clean evaluation accuracy 是正常现象。例如 W4 replay 最终 train-mode accuracy 为 91.57%，但 clean train sanity check 为 98.73%；L3-lowLR replay 的 clean train sanity check 为 99.63%。

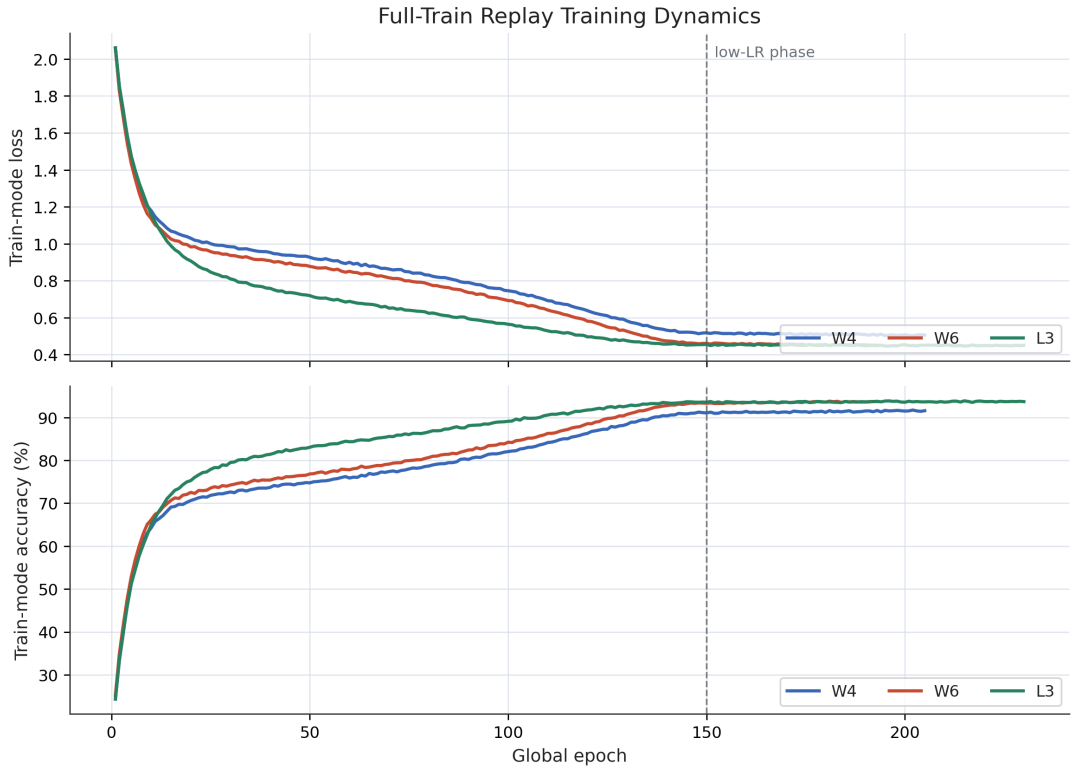


图 9 Full-train replay training dynamics。曲线为 train-mode 指标，竖线表示 epoch 150 后进入 explicit low-LR fine-tuning。

W4 和 L3 的参数量相同，平均 epoch time 分别为 22.55 s 和 22.87 s；W6 参数量为 13.14M，平均 epoch time 为 40.36 s。训练过程中曾观察到 GPU utilization 偏低的

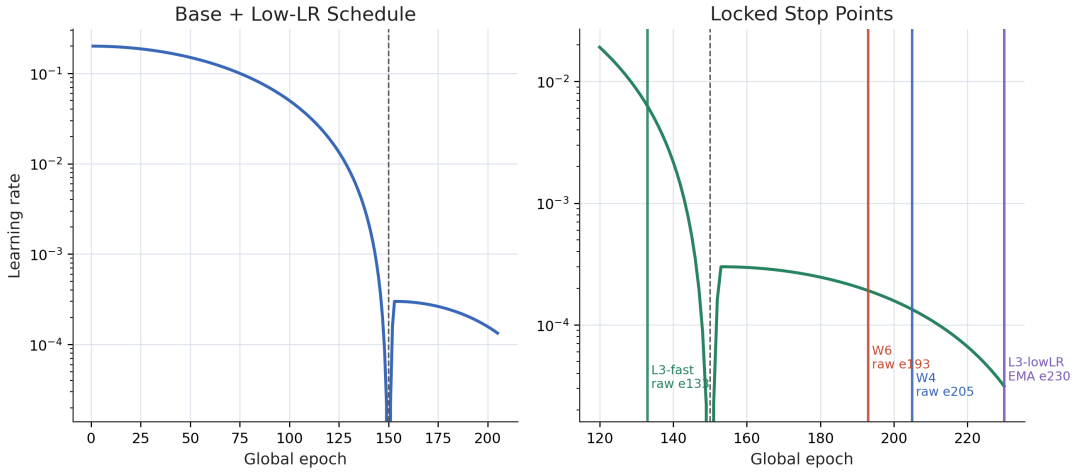


图 10 Full-train replay 学习率与 locked stop points。low-LR scheduler 保持 100-epoch 时间尺度，各模型只是在预声明 epoch 停止。

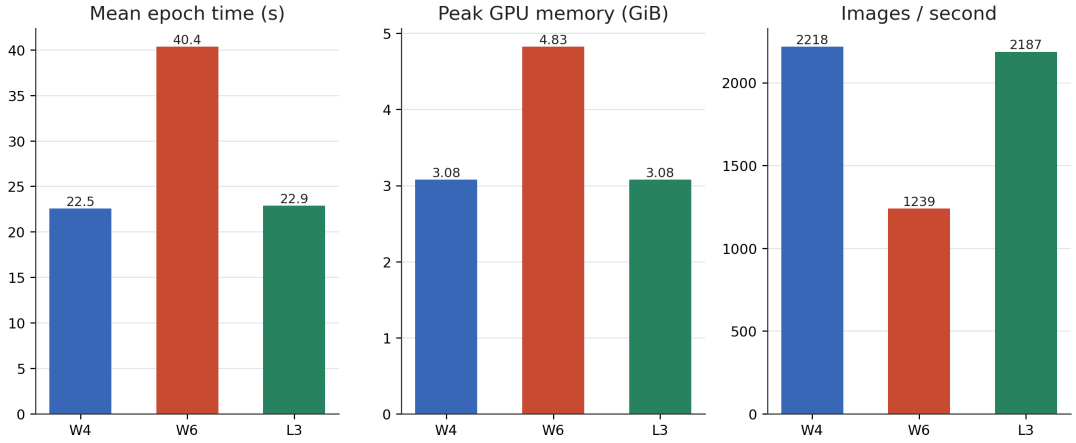


图 11 Full-train replay 资源摘要。W6 的参数量和显存更高，平均 epoch time 明显长于 W4/L3。

问题，因此 replay launcher 对三组训练设置了 CPU affinity，最终资源日志显示 GPU utilization 恢复到正常水平。

4 Official Test Results

4.1 Locked Rows

full-train replay official test 只包含四行：W4 raw e205、W6 raw e193、L3-fast raw e133 和 L3-lowLR EMA e230。它们在 `fulltrain\_replay\_test\_lock.json` 中固定，且 evaluator 会检查 checkpoint sha256。评估策略为 clean/eval transform、standard cross-entropy loss、no horizontal-flip TTA。

W6 在 locked replay rows 中取得最高 official test accuracy，为 96.26%。L3-lowLR EMA 达到 96.10%，略高于 L3-fast raw 的 96.02%，但该差异不用于 test 后二次选择，而是作为两个预声明问题的并列报告。W4 replay 达到 95.55%，略高于早期 original W4

表 9 Full-train replay official test 结果。四行均在测试前锁定。

Row	Model	Weights	Params	Test acc	Test error	Test loss
1	W4 full-train replay	raw e205	5.85M	95.55%	4.45%	0.1489
2	W6 full-train replay	raw e193	13.14M	96.26%	3.74%	0.1341
3	L3 full-train fast	raw e133	5.85M	96.02%	3.98%	0.1455
4	L3 full-train lowLR	EMA e230	5.85M	96.10%	3.90%	0.1404

full-train row 的 95.52%，说明新的 replay 协议没有削弱 W4 基线。

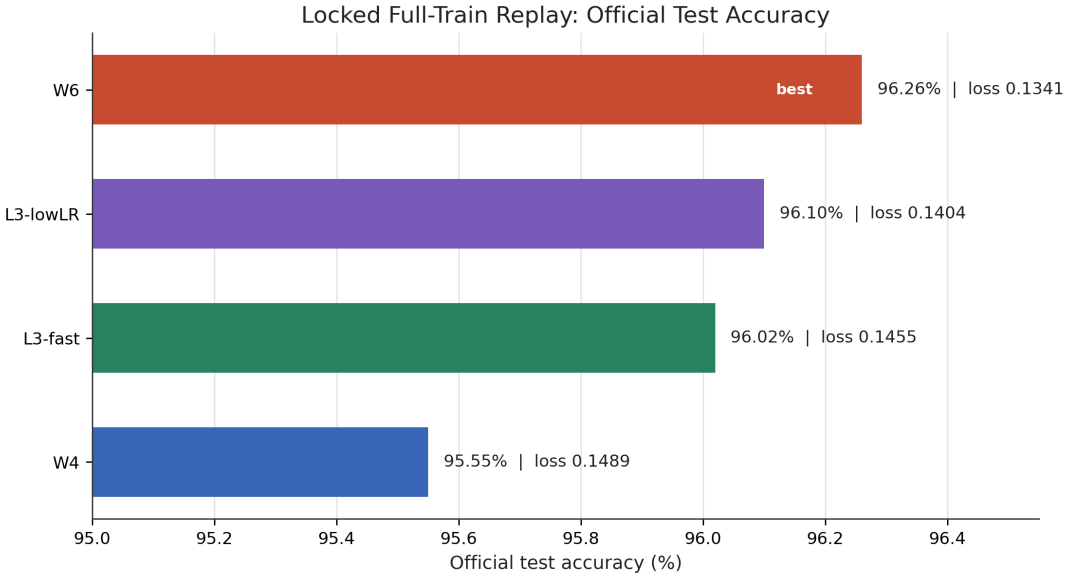


图 12 Full-train replay official test accuracy。W6 是四个 locked replay rows 中准确率最高的模型。

4.2 Official-Test Protocol Interpretation

replay 结果的可信度主要来自测试协议。假如在看到 official test 之后再调整 TTA、EMA、epoch 或 checkpoint，那么测试集就会被间接用于模型选择。本轮 replay 避免了这一点：四个 checkpoint 路径和 hash 在测试前锁定；official test evaluator 只接受 locked rows；测试后没有 post-test tuning、post-test training 或额外 checkpoint replacement。结果冻结在 `results/fulltrain_replay_20260611/metrics/fulltrain_replay_official_test_results.csv` 和对应 JSON 中。

因此，L3-fast 和 L3-lowLR 可以同时出现在主表中，但不能根据 test accuracy 再进行二选一。它们在 official test 前已经被定义为不同问题：L3-fast 测试 150-epoch base recipe 的早期最佳点，L3-lowLR 测试低学习率 + EMA 的扩展点。

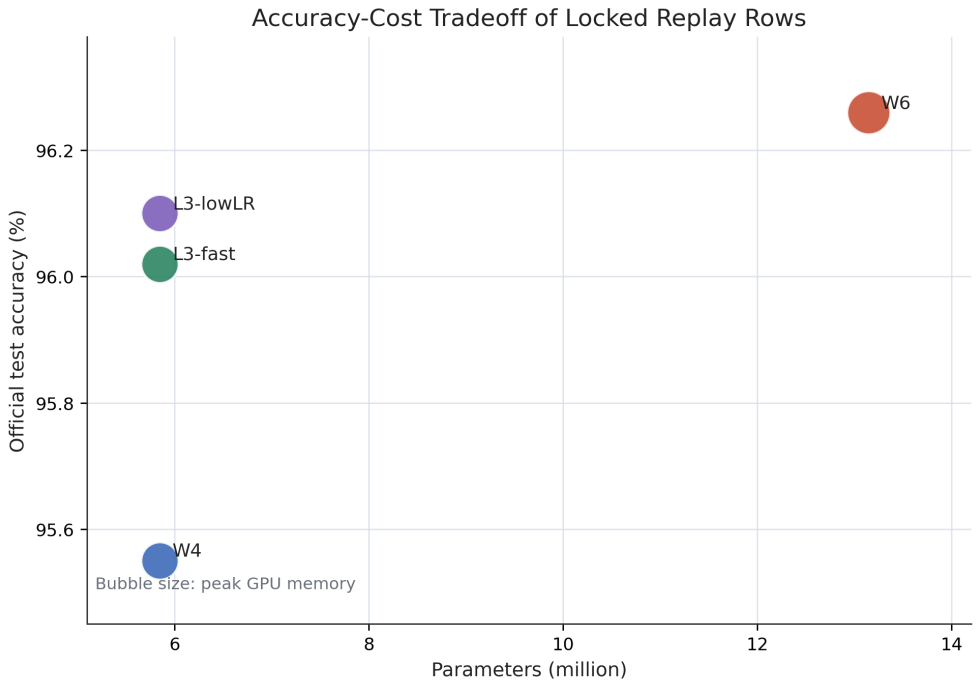


图 13 Locked replay rows 的 accuracy-cost tradeoff。W6 准确率最高，但参数量和显存成本也最高。

4.3 Classwise Performance and Confusion Matrix

四个 replay rows 的 classwise pattern 比较一致。automobile、frog、ship、horse 等类别通常接近或超过 97%；cat 和 dog 仍然是主要弱项。W4 的 cat accuracy 为 88.1%，W6 提升到 90.6%，L3-fast 和 L3-lowLR 分别为 90.8% 和 90.7%。这符合 CIFAR-10 中动物类别纹理相似、分辨率较低、姿态变化较大的特点。

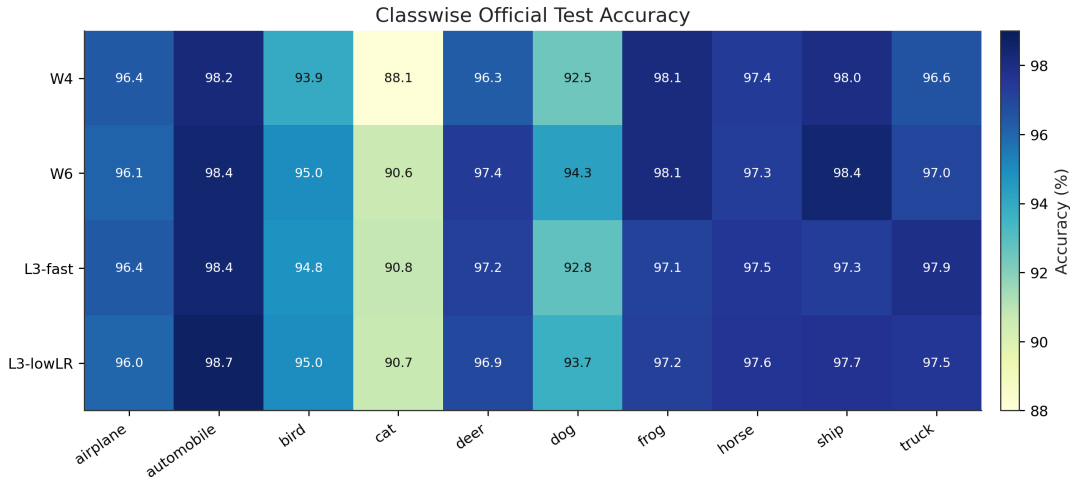


图 14 Full-train replay classwise official test accuracy。四个 locked rows 的弱项都集中在 cat/dog 等细粒度动物类别。

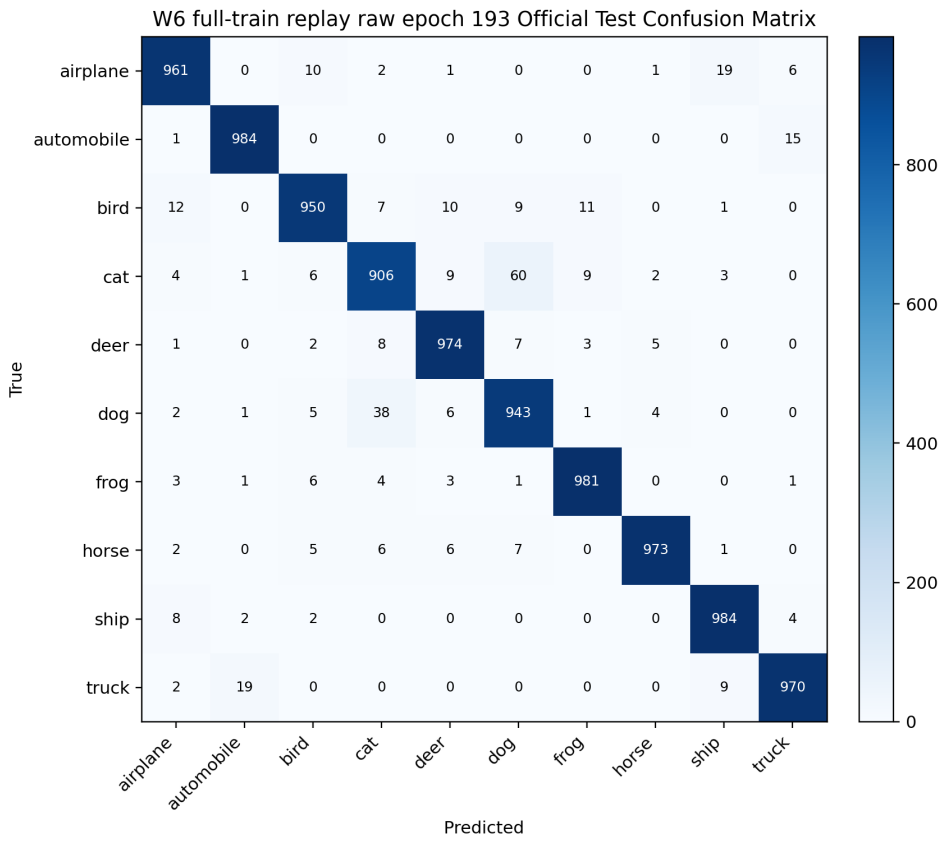


图 15 W6 replay official test confusion matrix。W6 是 locked replay rows 中 accuracy 最高的模型，错误仍主要集中在视觉相近类别之间。

5 BatchNorm Mini-Research

5.1 Controlled Comparison Design

BatchNorm 部分的目标是分析 BN 对优化过程的影响，而不仅是报告是否提升最终准确率。实验使用 VGG-A no BN 和 VGG-A BN 作为受控对照：主干结构一致，主要差别是卷积层后是否加入 BatchNorm。该实验只使用 `train_dev`/`val_dev`，不使用 official test。

BN P0 包含多个 probe：受控 VGG-A 训练比较、validation threshold reaching、required LR envelope、extended LR stability、scale-invariance probe、directional loss profile、gradient predictiveness 和 gradient Lipschitz estimate。这些 probe 从不同角度观察 BN 是否改变优化曲面和梯度局部行为。

5.2 Training Dynamics

训练曲线显示，BN 版本在相同 epoch budget 下获得更高 validation accuracy，并且更早跨过 85%、88% 和 89% 这些阈值。no-BN 版本最终没有达到 89% validation accuracy，而 BN 版本在 epoch 38 达到。因此，BN 的优势不仅体现在最终点，也体现在更有效的训练路径上。

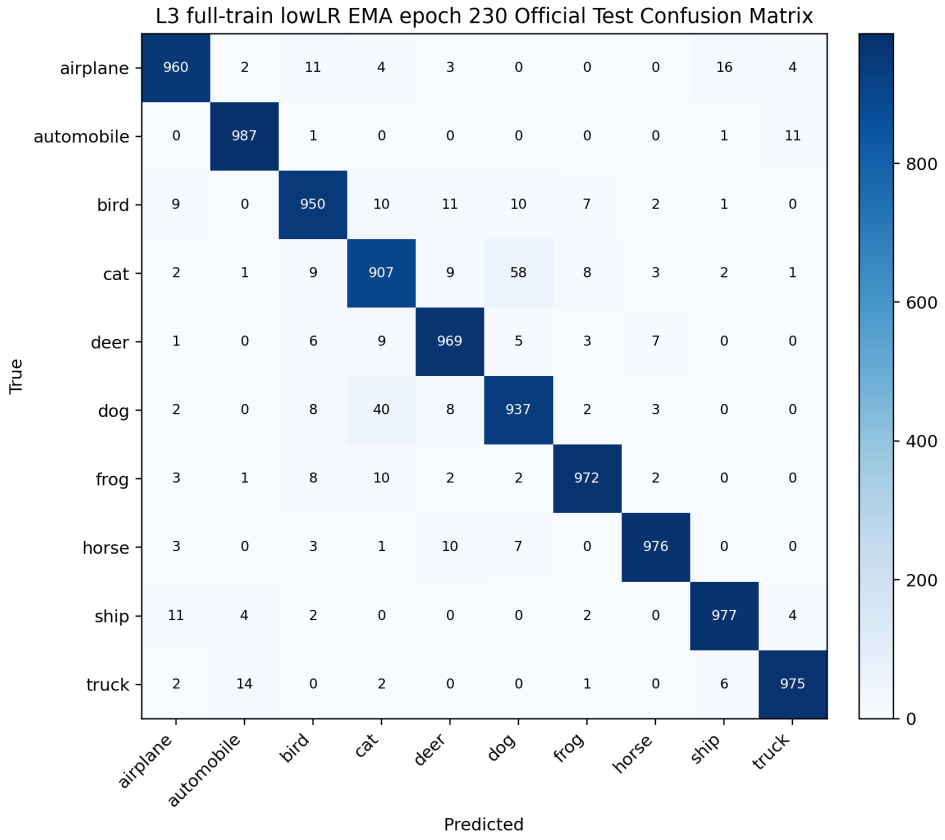


图 16 L3-lowLR replay official test confusion matrix。该 row 使用 EMA weights，官方测试准确率为 96.10%。

表 10 BN P0 摘要结果。

Experiment	No-BN	BN	Interpretation
Controlled VGG-A best val acc	88.48%	89.62%	BN 提升验证准确率 1.14pp
Epoch reaching 85% val acc	22	19	BN 更早达到阈值
Epoch reaching 88% val acc	38	35	BN 更早达到阈值
Epoch reaching 89% val acc	not reached	38	BN 达到 no-BN 未达到的阈值
Required LR envelope final width	0.9502	0.8563	BN 最终 envelope 更窄
Expanded LR largest usable LR	0.05	0.20	BN 在短程压力测试中承受更高 base LR
Symmetric prediction error	0.6476	0.5171	BN 的局部一阶预测误差更低
Gradient cosine similarity	0.3553	0.4352	BN 的梯度方向一致性更好
Gradient Lipschitz estimate best-val mean	32.1262	32.7714	不能声称 BN 一定降低 Lipschitz estimate

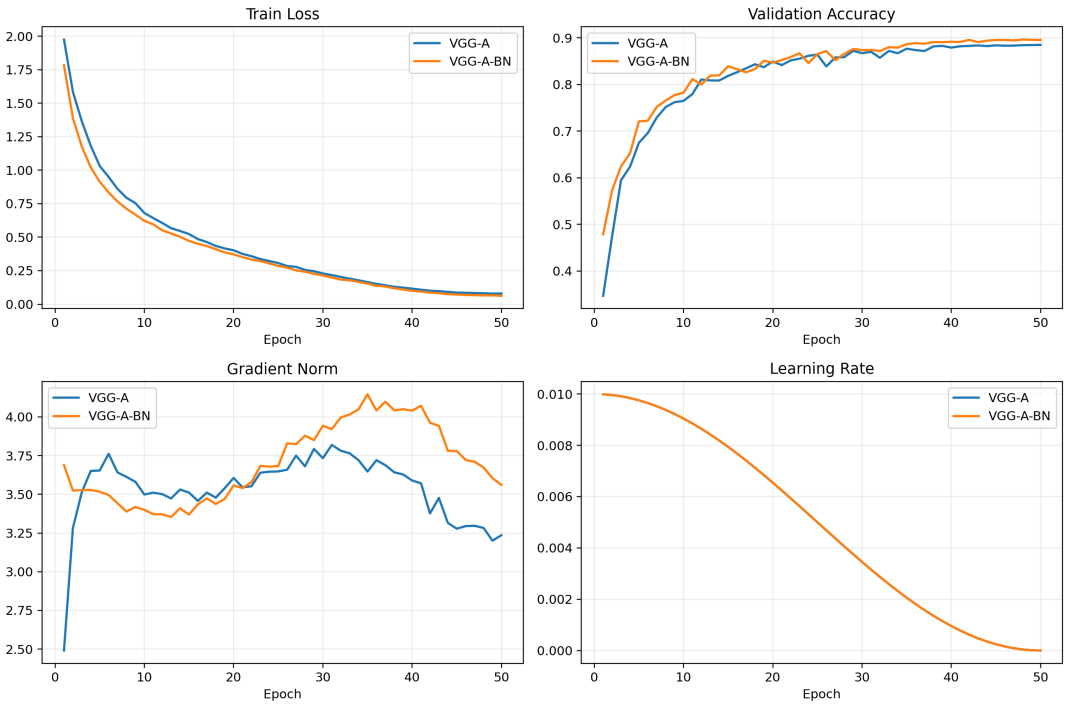


图 17 BN P0 training dynamics dashboard。BN 版本在验证准确率和阈值达到速度上均优于 no-BN。

5.3 Learning-Rate Envelope and Stability

required LR envelope 用于观察不同 learning rate 下训练轨迹的 spread。实验结果显示，BN 的 mean width 为 0.7671，no-BN 为 0.7561，因此不足以支持 BN 在全程均匀缩小 envelope 的结论。但在 final width 和 max width 上，BN 分别为 0.8563 和 1.1370，低于 no-BN 的 0.9502 和 1.2806。更合适的解释是：在本设置中，BN 可以改善部分阶段的轨迹稳定性，但不能概括为所有学习率条件下都更稳定。

5.4 Scale Invariance

BN 的一个重要性质是 train-mode batch statistics 可以抵消前层权重缩放带来的激活尺度变化。scale-invariance probe 对卷积权重做 rescaling，比较 loss 和预测是否变化。no-BN 的 loss 和预测会明显改变；BN 的 train-mode loss change 约为 1.1×10^{-5}，flip rate 为 0。图中同时保留 BN eval-mode running-statistics 结果作为 caveat：该模式并不保持这种尺度不变性。因此，支持的结论应限定为 train-mode batch-statistics 下的 reparameterization 作用。

5.5 Directional Profile and Gradient Predictiveness

directional loss profile 分别沿 gradient direction 和 random direction 做局部扰动。BN 在 d_grad 方向的 mean absolute loss delta 为 0.3503，小于 no-BN 的 0.4370；在 d_random 方向为 0.000072，小于 no-BN 的 0.000234。该结果说明，BN 在这些局部方

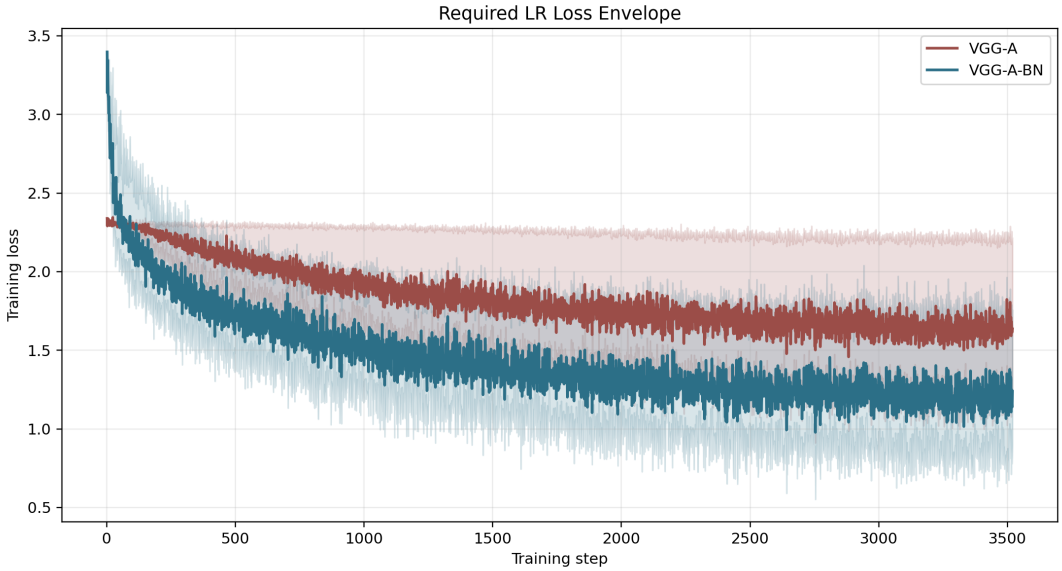


图 18 BN required loss envelope。BN 在 final/max width 上更窄，但 mean width 并非更小。

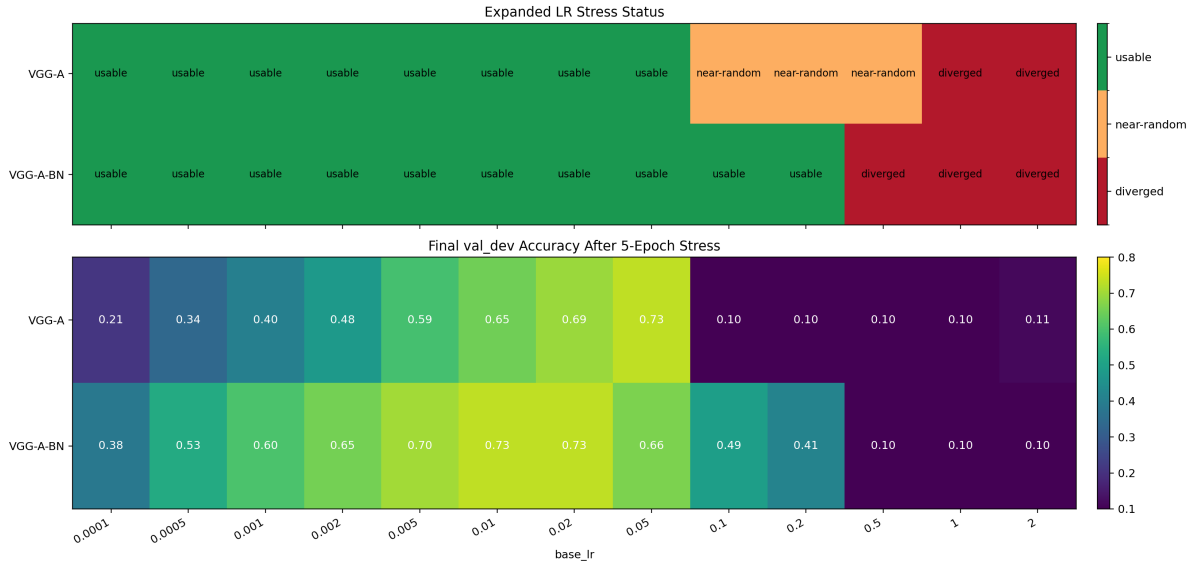


图 19 BN learning-rate stability heatmap。上图使用三状态标记：usable、near-random 和 diverged；下图给出连续的 final validation accuracy。扩展短程压力测试中，VGG-A no BN 的 largest usable base LR 为 0.05，VGG-A BN 为 0.20。

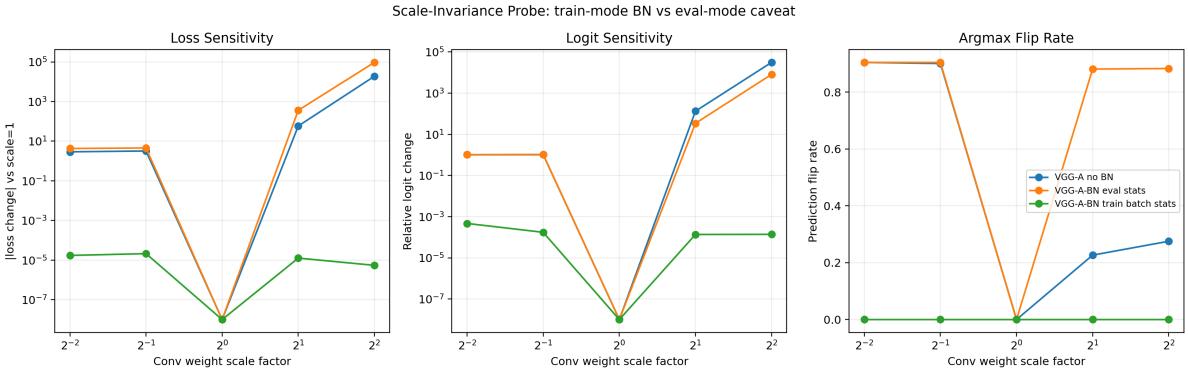


图 20 BN scale-invariance probe。train-mode BN 在卷积权重缩放下几乎保持 loss、logits 和预测不变；no-BN 与 eval-mode running statistics 对缩放敏感。右侧 argmax flip rate 是离散预测指标，极端缩放下可能饱和。

向上的 loss change 更小。

gradient predictiveness probe 进一步比较一阶梯度对局部 loss 变化的预测能力。原始 relative error 容易被 actual loss change 很小的点放大，因此报告使用更稳健的 symmetric prediction error：BN 为 0.5171，低于 no-BN 的 0.6476。BN 的 gradient cosine similarity 为 0.4352，高于 no-BN 的 0.3553；relative gradient change 为 1.0037，低于 no-BN 的 3.0477。这些结果共同支持 BN 改善局部线性预测和梯度方向一致性的结论。

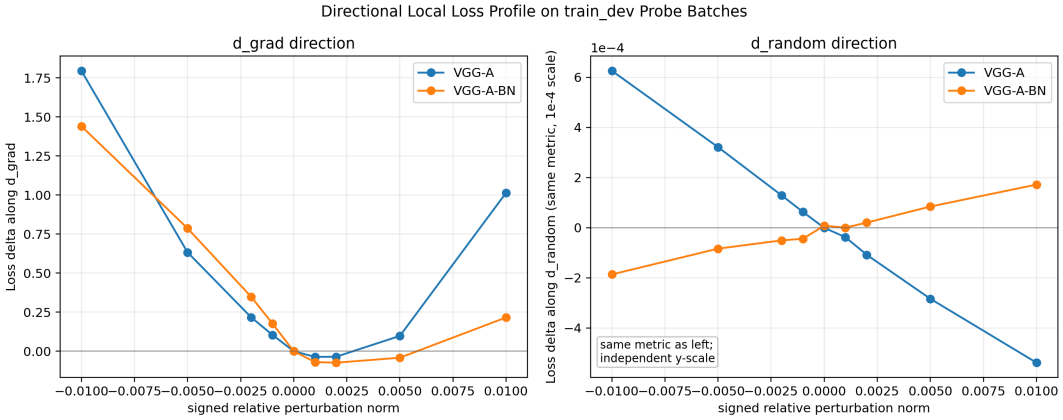


图 21 BN directional loss profile。左右两个 panel 使用同一个评价指标 loss delta，但方向不同：左侧沿 gradient direction，右侧沿 random direction。右侧 y-axis 使用 10^{-4} 量级的独立尺度，因此不能和左侧的绝对高度直接比较。

5.6 Supported Claims and Non-Claims

本项目对 BN 的结论保持谨慎。可以支持的结论包括：BN 提升受控 VGG-A 的验证准确率；BN 让模型更早达到若干 validation accuracy threshold；BN 在 expanded short LR stress 中承受更高 usable base LR；BN 在 train-mode scale-invariance probe 中几乎不受卷积权重缩放影响；BN 改善了若干局部梯度预测性指标。

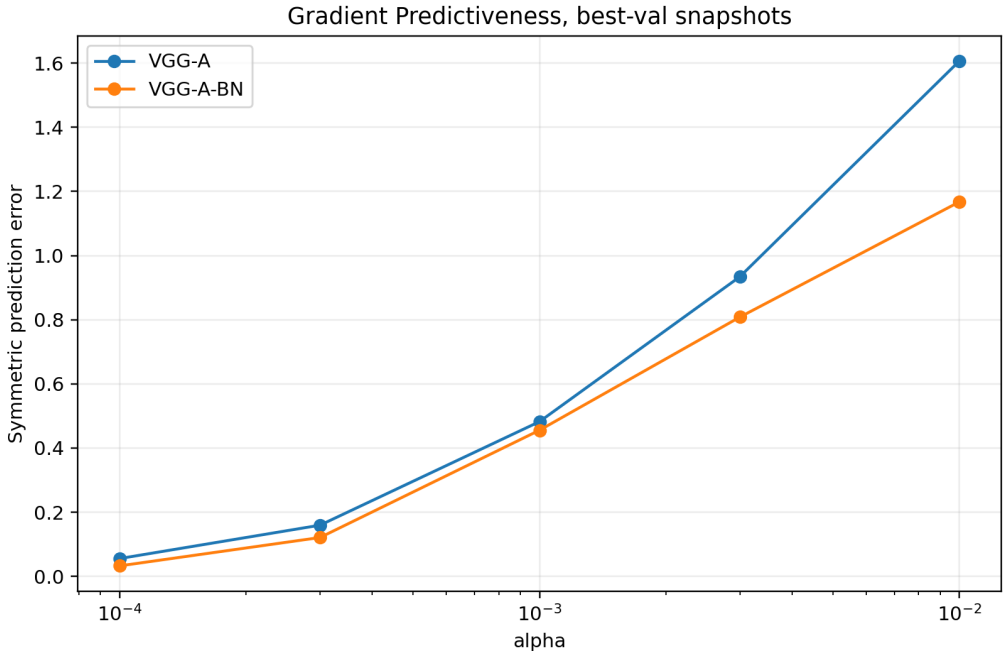


图 22 BN gradient predictiveness vs. alpha。使用 symmetric prediction error 后，BN 的局部一阶预测误差更低。

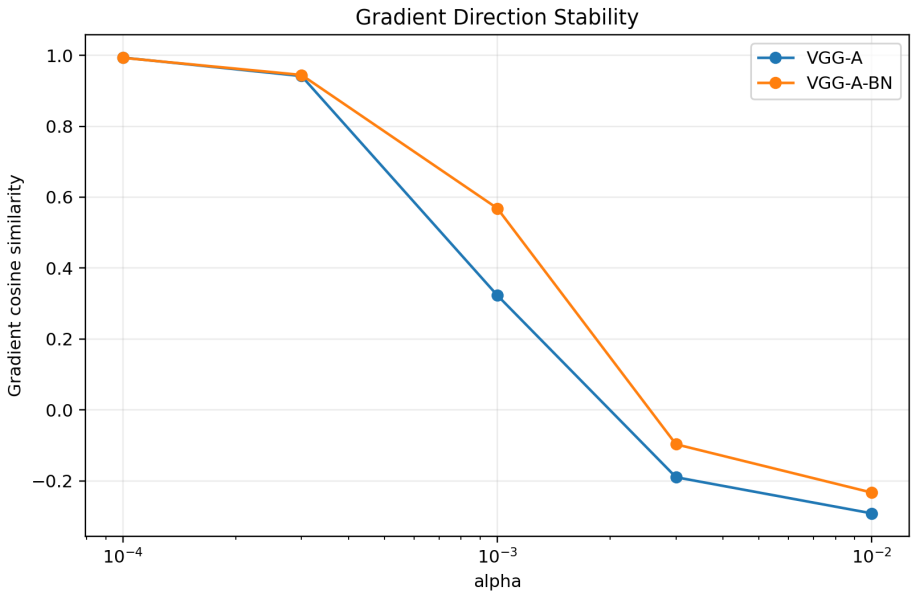


图 23 BN gradient cosine similarity。BN 的梯度方向一致性更好。

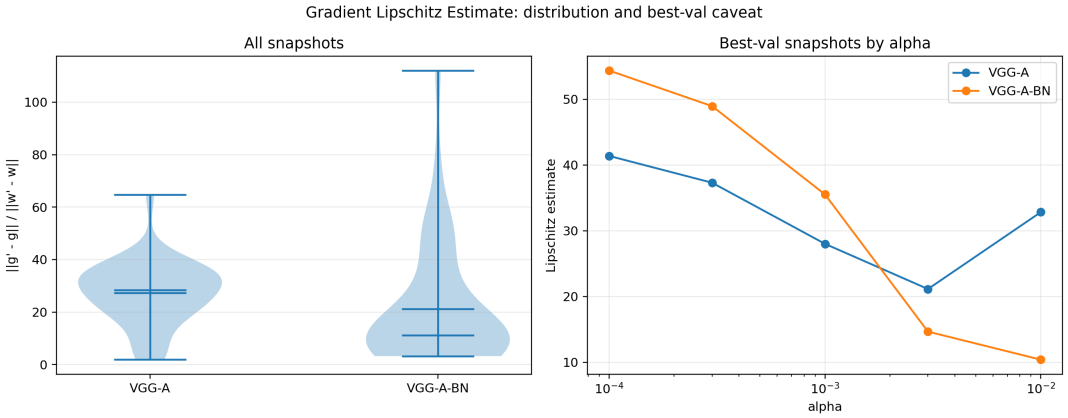


图 24 BN gradient Lipschitz estimate。all-snapshot 分布和 best-val snapshot 不给出完全相同的排序，因此这里只作为谨慎的 non-claim 证据。

同样需要明确的是，本文结果不支持以下更强结论：BN 在所有学习率上都缩小 loss envelope；short LR stress 可以推广为所有模型和训练预算下的最大稳定 learning rate 规律；BN 一定降低 gradient Lipschitz estimate；单一 VGG-A/CIFAR-10 设置可以推广到所有模型和数据集。保留这些边界有助于避免将局部证据解释为普遍规律。

6 Error Analysis and Discussion

6.1 Where the Replay Models Still Fail

locked replay rows 的 official test error 位于 3.74% 到 4.45% 之间。W6 error 最低，为 3.74%；L3-lowLR 为 3.90%；L3-fast 为 3.98%；W4 为 4.45%。从 classwise accuracy 看，cat 和 dog 仍然明显低于 automobile、ship、horse 等类别。造成这种现象的原因主要有三点：CIFAR-10 图像分辨率只有 32×32，动物类别的局部纹理和轮廓容易混淆；同类内部姿态差异较大，尤其 cat/dog 在低分辨率下边界并不清晰；数据集中背景和主体比例变化较大，模型可能在部分样本上依赖背景相关性。

confusion matrix 显示，一部分错误集中在视觉上相近的类别之间。这说明 replay 模型的错误并不只来自训练不足，也包含数据集本身的 ambiguity。进一步提升可能需要更强的数据增强、更长训练、更大模型、模型集成或 test-time augmentation；这些改动均未在 official test 后加入，因为 replay 协议已经锁定。

6.2 How to Interpret W4, W6, and L3

如果只看 replay official test accuracy，W6 是四行中最高的模型，达到 96.26%。但 W6 使用 13.14M 参数，而 W4/L3 只有 5.85M；W6 replay 峰值显存为 4.83 GiB，平均 epoch time 为 40.36 s，明显高于 W4/L3。因此 W6 更准确的定位是 “最高准确率的 larger model”，而不是无条件最优模型。

L3 的两行回答的是不同问题。L3-fast raw e133 在不进入 low-LR replay endpoint 的情况下达到 96.02%；L3-lowLR EMA e230 达到 96.10%。两者差距只有 0.08 percentage

points，说明 L3 recipe 的早期点已经具备较强性能，而 low-LR + EMA 带来小幅额外提升。由于两行在测试前预声明，不能在 test 后只保留更高的一行。

6.3 Protocol Lessons

本项目的主要实验经验是，严格协议比单个准确率数字更重要。开发阶段可以充分使用 validation set 做搜索，但一旦 replay lock 创建，后续就不应再根据 official test 做任何调整。full-train replay 的价值在于把 dev-val 选择映射到完整 50,000 张训练图像上，同时保留“测试前锁定”的解释边界。

第二个经验是，结果解释需要和成本一起看。W6 official test accuracy 最高，但也最慢、最大；VGG-A 参数更多，但不如 PreActResNet replay rows；BN 增加的参数几乎可以忽略，却明显改变优化行为。这些现象说明，模型比较不应只看单列 accuracy。

第三个经验是，机制分析应当包含 non-claims。BN 的确改善了本项目中的 VGG-A 优化，并且 expanded short LR stress 显示 BN 能承受更高 usable base LR；但实验结果没有支持所有常见直觉说法。例如 required LR envelope 的 mean width 没有下降，best-val Lipschitz estimate mean 也没有下降。如果报告只保留正向结论，会掩盖实验本身的边界。

7 Conclusion

本项目在 CIFAR-10 上完成了一个严格验证集控制的分类实验。开发阶段使用 45,000/5,000 的训练/验证划分完成模型选择和 stop point 决策，随后在完整 50,000 张官方训练图像上进行 full-train replay。replay official test 在四个 checkpoint 全部锁定后执行，评估策略为 clean/eval transform，不使用 horizontal-flip TTA。四个 locked replay rows 中，W6 达到最高 official test accuracy 96.26%，错误率为 3.74%；L3-lowLR 为 96.10%；L3-fast 为 96.02%；W4 为 95.55%。

从模型比较看，SimpleCNN 提供了 86.72% 的低复杂度 baseline；VGG-A no BN 和 VGG-A BN 分别达到 87.85% 和 89.17%，说明 BN 对 VGG-A 有明确帮助；PreActResNet replay rows 在参数量低于或接近 VGG-A 的情况下取得显著更高的准确率。W6 是准确率最高的 larger model，但 W4/L3 以 5.85M 参数达到 95.55%–96.10%，展示了更好的参数效率。

BN mini-research 支持一个谨慎但清晰的结论：在受控 VGG-A/CIFAR-10 设置中，BN 改善验证准确率、收敛速度、expanded short LR robustness、train-mode scale invariance 和若干局部梯度预测性指标；但它不支持“BN 总是更平滑”或“这些短程压力测试能直接推广到任意训练预算”等过强说法。最终，本文的核心贡献不只是某个单独模型，而是一套从开发验证、模型选择、最终锁定到测试冻结的完整实验流程。

参考文献

[1] A. Krizhevsky. Learning Multiple Layers of Features from Tiny Images. Technical report, University of Toronto, 2009.

[2] K. He, X. Zhang, S. Ren, and J. Sun. Deep Residual Learning for Image Recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016.

[3] S. Ioffe and C. Szegedy. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. In Proceedings of the International Conference on Machine Learning, 2015.

[4] S. Santurkar, D. Tsipras, A. Ilyas, and A. Madry. How Does Batch Normalization Help Optimization? In Advances in Neural Information Processing Systems, 2018.